**Московский физико-технический институт**
**Физтех-школа прикладной математики и информатики**

# ОТЧЕТ

по математическому практикуму

## Тема работы:
## Энтропийный оптимальный транспорт: анализ двойственности и методы оптимизации

**Научный руководитель:**
Агафонов А.Д.
Гасников А.В.

**Выполнил:**
студент группы Б05-406
Подсветов И.Р.

Долгопрудный, 2026

# Постановка транспортной задачи

Рассмотрим двудольный граф, который моделирует перемещение груза от источников к потребителям. В качестве источников могут быть склады или шахты, а в качестве потребителей - магазины, заводы. Также эта задача способна моделировать поведение людей, тогда источники - жилые районы, а потребители - рабочие районы.

Введем основные обозначения:

$O = \{O_i\}_{i=1}^n$, где $|O| = n$ — множество источников.

$D = \{D_j\}_{j=1}^m$, где $|D| = m$ — множество потребителей.

$d_{ij}$ — поток (например, количество груза), который нужно перевезти из $O_i$ в $D_j$.

$T_{ij}$ — цена перевозки единицы груза от источника $i$ к потребителю $j$ (определяется из условий задачи).

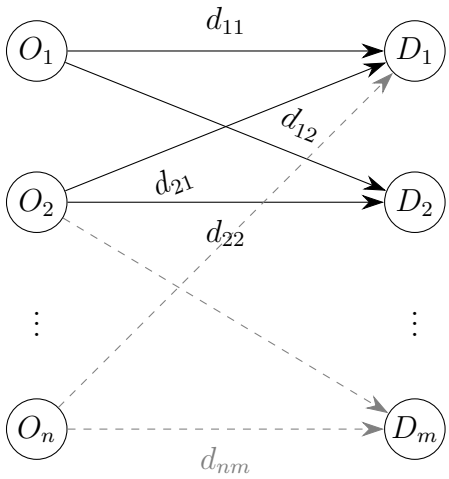


Рис. 1: Схематичное представление транспортной задачи.

Транспортная задача имеет ограничения (законы сохранения):

$\sum_{j=1}^m d_{ij} = O_i$ — весь груз из источника $i$ должен быть вывезен.

$\sum_{i=1}^n d_{ij} = D_j$ — потребности узла $j$ должны быть удовлетворены.

$d_{ij} \geqslant 0$ — условие неотрицательности потока.

$\sum_{i=1}^n O_i = \sum_{j=1}^m D_j$ — условие баланса.

# Формирование модели

В классическом случае мы минимизируем суммарные расходы:

$$\min_d \sum_{i,j} T_{ij} d_{ij} \tag{1}$$

Однако линейная целевая функция имеет ряд недостатков:
1) Нестабильность решения: поскольку целевая функция линейна, а область допустимых решений представляет собой многогранник, минимум всегда достигается в одной из его крайних точек (вершин). При малом изменении вектора стоимостей $T$ оптимальная точка может «перепрыгнуть» из одной вершины в другую, полностью меняя структуру потоков.
2) Разреженность: решение будет представлять собой нули везде, кроме нескольких "выгодных"маршрутов. В реальности (особенно при моделировании людей) потоки распределяются более равномерно.

Для решения этих проблем добавляют энтропийный регуляризатор:

$$\min_d \left[ \sum_{i,j} T_{ij} d_{ij} + \gamma \sum_{i,j} d_{ij} \ln d_{ij} \right] \tag{2}$$

$\gamma$ - параметр регуляризации
Функция $f(d) = d \ln d$ является строго выпуклой. Добавляя её, мы создаем плавный минимум внутри допустимой области, что обеспечивает гладкую зависимость решения от входных данных.
Интересна также интерпретация из термодинамики. Процесс можно описать через минимизацию свободной энергии Гельмгольца $F = E - TS$.

Внутренняя энергия системы: $E = \sum T_{ij} d_{ij}$

Энтропия системы: $S = -\sum d_{ij} \ln d_{ij}$

Температура: $T$ (в нашей модели роль температуры играет параметр $\gamma$)

При $T \to 0$ энтропия не важна (система стремится к минимуму энергии — классическая задача). При $T \to \infty$ доминирует энтропия (максимальный хаос, груз распределяется равномерно). При умеренном $T$ мы ищем баланс.

## Векторно-матричный вид (переход к ЭЛП)

Для удобства оптимизации перейдем к задаче энтропийно-линейного программирования (ЭЛП), вытянув переменные в векторы:

$x = (d_{11}, d_{12}, \ldots, d_{nm})^T \in \mathbb{R}^N$, где $N = nm$.

$c = (T_{11}, T_{12}, \ldots, T_{nm})^T \in \mathbb{R}^N$.

$\sum T_{ij} d_{ij} = \langle c, x \rangle = \sum_{k=1}^N c_k x_k$.

$b = (O_1, \ldots, O_n, D_1, \ldots, D_m)^T \in \mathbb{R}^{n+m}$.

$A$ — матрица инцидентности размера $(n+m) \times N$. Она состоит из 0 и 1 и превращает систему ограничений в линейное уравнение $Ax = b$, $x_i \geqslant 0$

Модифицированная целевая функция:

$$\min_{x \in \mathbb{R}^N} \left[ \sum_{k=1}^{N} c_k x_k + \gamma \sum_{k=1}^{N} x_k (\ln x_k - 1) \right] \tag{3}$$

Замена слагаемого $x \ln x$ на $x(\ln x - 1)$ делается для удобства дифференцирования в градиентных методах. Если $f(x) = x \ln x$, то $f'(x) = \ln x + 1$. Если же $g(x) = x(\ln x - 1)$, то $g'(x) = \ln x$. На точку минимума это не влияет, так как:

$$\sum x_k (\ln x_k - 1) = \sum x_k \ln x_k - \sum x_k$$

Поскольку $\sum x_k = \sum O_i = \text{const}$, мы просто вычитаем константу из целевой функции, что не меняет положение минимума.

В задаче удобно перейти от абсолютных объемов груза к долям (вероятностям). Пусть $V = \sum_{i,j} d_{ij}$ — общий грузооборот.

Поделив обе части ограничений на $V$, мы переходим к нормированным величинам:

$$p_{ij} = \frac{d_{ij}}{V}, \quad O'_i = \frac{O_i}{V}, \quad D'_j = \frac{D_j}{V}$$

Тогда: $\sum_{i=1}^{n} O'_i = \sum_{j=1}^{m} D'_j = 1$.

Важно отметить, что ограничение на общую сумму вероятностей $\sum_{i,j} p_{ij} = 1$ выполняется автоматически, если выполнена система $Ax = b'$. Действительно, если взять уравнения для источников $\sum_j p_{ij} = O'_i$ и просуммировать их по всем $i$, мы получим:

$$\sum_{i=1}^{n} \left( \sum_{j=1}^{m} p_{ij} \right) = \sum_{i=1}^{n} O'_i = 1.$$

Соглашение об обозначениях: далее во всей работе мы будем предполагать, что данные уже отнормированы, чтобы не перегружать формулы штрихами и новыми переменными, мы продолжим использовать исходные обозначения $d_{ij}, O_i, D_j$, подразумевая под ними их отнормированные версии.

## Двойственная задача

Решать прямую задачу (3) при условии $Ax = b$ проблематично, так как это требует поиска решения в подпространстве, определяемом системой линейных уравнений. Исполь-

зование стандартных градиентных методов в данном случае затруднено.

Из математического анализы мы знаем, что можно воспользоваться методом множителей Лагранжа. Перейдем от прямой задачи к так называемой двойственной. Для построения двойственной задачи выпишем функцию Лагранжа для прямой задачи. Для начала рассмотрим задачу без дополнительного ограничения $\sum_{i=1}^{N} x_i = 1$:

$$L(x, y) = \sum_{i=1}^{N} c_i x_i + \gamma \sum_{i=1}^{N} x_i(\ln x_i - 1) + \langle y, Ax - b \rangle,$$

где $y \in \mathbb{R}^{n+m}$ — вектор двойственных переменных.

**Краткое пояснение перехода к двойственной задаче:**
С точки зрения теории оптимизации, исходную задачу с ограничениями можно представить как игру двух игроков (минимаксную задачу):

$$\min_x \max_y L(x, y)$$

Смысл в том, что если ограничение $Ax = b$ не выполнено, то внутренний максимум по неограниченному $y$ «оштрафует» систему, устремив значение в $+\infty$. А если выполнено, то останется просто $\min_x f(x)$.

Поскольку наша функция (энтропия) является выпуклой, а ограничения — линейными, выполняется теорема о минимаксе (сильная двойственность). Она позволяет законно поменять порядок операций местами:

$$\min_x \max_y L(x, y) = \max_y \min_x L(x, y)$$

Внутренняя задача $\min_x L(x, y)$ называется двойственной функцией $g(y)$. Находя минимум Лагранжиана по $x$ в явном виде и подставляя найденное выражение $x^*(y)$ обратно, мы фактически «выполняем» внутреннюю задачу $\min_x$. Переменная $x$ при этом «выкидывается», и нам остается только решить внешнюю задачу максимизации по $y$: $\max_y g(y)$.

Найдем минимум Лагранжиана по $x$. Из условия $\nabla_x L(x, y) = 0$ получаем:

$$\frac{\partial L}{\partial x_i} = c_i + \gamma \ln x_i + (A^T y)_i = 0 \quad \Longrightarrow \quad \ln x_i = -\frac{c_i + (A^T y)_i}{\gamma}$$

$$x_i^*(y) = \exp\left(-\frac{c_i + (A^T y)_i}{\gamma}\right) \tag{4}$$

Подставляя $x_i^*(y)$ обратно в функцию Лагранжа, получаем двойственную функцию $g(y)$:

$$g(y) = \min_x L(x, y) = -\langle y, b\rangle - \gamma \sum_{i=1}^{N} \exp\left(-\frac{c_i + (A^T y)_i}{\gamma}\right)$$

Двойственная задача заключается в максимизации $g(y) \to \max_y$.

**Двойственная задача с ограничением $\sum x_i = 1$:**

Введем дополнительный множитель Лагранжа $\alpha \in \mathbb{R}$ для ограничения на сумму:

$$L(x, y, \alpha) = \sum_{i=1}^{N} c_i x_i + \gamma \sum_{i=1}^{N} x_i(\ln x_i - 1) + \langle y, Ax - b\rangle - \alpha\left(\sum_{i=1}^{N} x_i - 1\right)$$

Условие $\nabla_x L(x, y) = 0$ дает:

$$c_i + \gamma \ln x_i + (A^T y)_i - \alpha = 0 \quad \Longrightarrow \quad x_i = \exp\left(\frac{\alpha - c_i - (A^T y)_i}{\gamma}\right)$$

Используя ограничение $\sum_{i=1}^{N} x_i = 1$, находим константу нормировки $e^{\alpha/\gamma}$ и получаем известное выражение (Softmax):

$$x_i^*(y) = \frac{\exp\left(-\frac{c_i + (A^T y)_i}{\gamma}\right)}{\sum_{k=1}^{N} \exp\left(-\frac{c_k + (A^T y)_k}{\gamma}\right)} \tag{5}$$

Подставляя это в Лагранжиан, получаем двойственную функцию $g(y)$. Для удобства перейдем к эквивалентной задаче минимизации $\varphi(y) = -g(y) \to \min_y$:

$$\varphi(y) = \langle y, b\rangle + \gamma \ln\left(\sum_{i=1}^{N} \exp\left(-\frac{c_i + (A^T y)_i}{\gamma}\right)\right) \to \min_{y \in \mathbb{R}^{n+m}}$$

В оптимизации свойства целевой функции определяют применимость методов (градиентного спуска, метода Ньютона и т.д.). Интересно посмотреть на свойства прямой и двойственной задач.

**Прямая задача** ($f(x) = \langle c, x\rangle + \gamma \sum x_i(\ln x_i - 1)$):

Выпуклость: Функция строго выпукла. Матрица Гессе $\nabla^2 f(x) = \operatorname{diag}\left(\frac{\gamma}{x_1}, \ldots, \frac{\gamma}{x_N}\right)$ положительно определена, так как $\gamma > 0$ и $x_i > 0$.

Сильная выпуклость: так как $x_i \leqslant 1$, то диагональные элементы Гессиана ограничены снизу: $\frac{\gamma}{x_i} \geqslant \gamma$. Значит, $\nabla^2 f(x) \succeq \gamma I$. Функция сильно выпукла.

Липшицевость (функции, градиента, гессиана): Нет. Градиент содержит $\ln x_i$, Гессиан содержит $\frac{1}{x_i}$, третья производная содержит $-\frac{1}{x_i^2}$. При приближении $x_i \to 0$ (что

естественно для транспортной задачи, где многие потоки нулевые) все производные стремятся к бесконечности. Функция и её производные не удовлетворяют условию Липшица.

**Двойственная задача** ($\varphi(y) = \langle y, b\rangle + \gamma \ln \sum \exp(\dots)$): Обозначим через $p(y)$ вектор-столбец, компоненты которого задаются формулой Softmax: $p_i(y) = x_i^*(y) \in (0,1)$. Тогда $\nabla\varphi(y) = b - Ap(y)$, а Гессиан равен $\nabla^2\varphi(y) = \frac{1}{\gamma}A(\mathrm{diag}(p) - pp^T)A^T$.

Липшицевость (функции, градиента и гессиана): Да, обладает всеми тремя свойствами. Так как $p_i(y) \in (0,1)$ для любых $y \in \mathbb{R}^{n+m}$, градиент, Гессиан и третьи производные ограничены константами на всем пространстве $\mathbb{R}^{n+m}$. Переход к двойственной задаче устранил проблему «взрывающихся» производных.

Выпуклость: Функция выпукла. Покажем это, исследовав квадратичную форму Гессиана. Для произвольного вектора $v$ имеем:

$$v^T\nabla^2\varphi(y)v = \frac{1}{\gamma}v^TA(\mathrm{diag}(p) - pp^T)A^Tv$$

Обозначим $z = A^Tv$. Тогда выражение примет вид:

$$\frac{1}{\gamma}z^T(\mathrm{diag}(p) - pp^T)z = \frac{1}{\gamma}\left(\sum_{i=1}^N p_iz_i^2 - \left(\sum_{i=1}^N p_iz_i\right)^2\right)$$

Поскольку $p_i \in (0,1)$ и $\sum p_i = 1$, вектор $p$ задает вероятностное распределение. Если рассматривать компоненты $z_i$ как значения случайной величины $Z$, принимаемые с вероятностями $p_i$, то полученное выражение в скобках — это в точности разность второго момента и квадрата математического ожидания, то есть дисперсия $\mathrm{Var}(Z)$:

$$\mathbb{E}[Z^2] - (\mathbb{E}[Z])^2 = \mathrm{Var}(Z) \geqslant 0$$

Так как дисперсия всегда неотрицательна, квадратичная форма $v^T\nabla^2\varphi(y)v \geqslant 0$. Матрица Гессе неотрицательно определена ($\nabla^2\varphi(y) \succeq 0$), функция выпукла.

Сильная выпуклость: Нет. Чтобы функция была сильно выпуклой, дисперсия $\mathrm{Var}(Z)$ должна быть строго больше нуля для любого ненулевого вектора $v$. Однако дисперсия равна нулю, когда случайная величина $Z$ является константой, то есть когда все компоненты вектора $z = A^Tv$ равны между собой. Если положить $z = (1,1,\dots,1)^T$, то $\mathrm{Var}(Z) = 0$, и квадратичная форма зануляется: $v^T\nabla^2\varphi(y)v = 0$. Такой ненулевой вектор $v$ всегда найдется: достаточно взять $v = (1,\dots,1,0,\dots,0)^T$ (единицы для

источников, нули для стоков). Следовательно, Гессиан имеет нулевые собственные значения, и сильной выпуклости нет.

## Классический градиентный спуск

В предыдущих пунктах было показано, что решение энтропийно-регуляризованной задачи оптимального транспорта сводится к минимизации двойственной функции $\varphi(y)$. Ключевым свойством прямо-двойственного перехода является то, что градиент двойственной функции в точности равен невязке ограничений прямой задачи:

$$\nabla\varphi(y) = b - Ax(y) \tag{6}$$

где $x(y)$ — матрица транспортного плана, восстановленная по двойственным переменным $y$. Таким образом, чтобы получить $\varepsilon$-приближенное решение исходной задачи (то есть добиться выполнения условий прямой задачи с точностью $\varepsilon$), нам необходимо сделать малой норму градиента двойственной функции: $\|\nabla\varphi(y)\| \leqslant \varepsilon$.

Рассмотрим применение к двойственной задаче метода обычного градиентного спуска:

$$y_{k+1} = y_k - \eta\nabla\varphi(y_k) \tag{7}$$

Ранее было доказано, что градиент функции $\varphi(y)$ удовлетворяет условию Липшица с константой $L$:

$$\|\nabla\varphi(u) - \nabla\varphi(v)\| \leqslant L\|u - v\| \quad \forall u, v \tag{8}$$

Используя формулу Ньютона-Лейбница, выразим значение функции в точке $y$ через интеграл по отрезку от $x$ до $y$:

$$\varphi(y) = \varphi(x) + \int_0^1 \langle\nabla\varphi(x + t(y - x)), y - x\rangle\, dt \tag{9}$$

Добавим и вычтем под знаком интеграла слагаемое $\langle\nabla\varphi(x), y - x\rangle$:

$$\varphi(y) = \varphi(x) + \langle\nabla\varphi(x), y - x\rangle + \int_0^1 \langle\nabla\varphi(x + t(y - x)) - \nabla\varphi(x), y - x\rangle\, dt \tag{10}$$

Применим неравенство КБШ к подынтегральному выражению, а затем воспользуемся свойством Липшицевости градиента:

$$\varphi(y) \leqslant \varphi(x) + \langle\nabla\varphi(x), y - x\rangle + \int_0^1 \|\nabla\varphi(x + t(y - x)) - \nabla\varphi(x)\| \cdot \|y - x\|\, dt \tag{11}$$

$$\varphi(y) \leqslant \varphi(x) + \langle \nabla\varphi(x), y - x\rangle + \int_0^1 L \cdot t\|y - x\| \cdot \|y - x\|\, dt \tag{12}$$

В итоге получаем результат, называемый леммой о достаточном убывании:

$$\varphi(y) \leqslant \varphi(x) + \langle \nabla\varphi(x), y - x\rangle + \frac{L}{2}\|y - x\|^2 \tag{13}$$

Подставим в это неравенство точки алгоритма градиентного спуска: $x = y_k$ и $y = y_{k+1} = y_k - \eta\nabla\varphi(y_k)$, где $\eta$ — пока произвольная длина шага:

$$\varphi(y_{k+1}) \leqslant \varphi(y_k) + \langle \nabla\varphi(y_k), -\eta\nabla\varphi(y_k)\rangle + \frac{L}{2}\| - \eta\nabla\varphi(y_k)\|^2 \tag{14}$$

$$\varphi(y_{k+1}) \leqslant \varphi(y_k) - \eta\|\nabla\varphi(y_k)\|^2 + \frac{L\eta^2}{2}\|\nabla\varphi(y_k)\|^2 \tag{15}$$

Вынесем квадрат нормы градиента за скобки:

$$\varphi(y_{k+1}) \leqslant \varphi(y_k) - \left(\eta - \frac{L\eta^2}{2}\right)\|\nabla\varphi(y_k)\|^2 \tag{16}$$

Чтобы гарантировать максимальное убывание функции на каждом шаге, нам необходимо максимизировать множитель перед нормой градиента, следовательно:

$$\eta = \frac{1}{L}$$

Подставляя оптимальный шаг обратно в неравенство, получаем окончательную оценку шага алгоритма:

$$\varphi(y_{k+1}) \leqslant \varphi(y_k) - \frac{1}{2L}\|\nabla\varphi(y_k)\|^2 \tag{17}$$

$$\varphi(y_{k+1}) \leqslant \varphi(y_k) - \frac{1}{L}\|\nabla\varphi(y_k)\|^2 + \frac{1}{2L}\|\nabla\varphi(y_k)\|^2 = \varphi(y_k) - \frac{1}{2L}\|\nabla\varphi(y_k)\|^2 \tag{18}$$

Перепишем полученное неравенство:

$$\frac{1}{2L}\|\nabla\varphi(y_k)\|^2 \leqslant \varphi(y_k) - \varphi(y_{k+1}) \tag{19}$$

Просуммируем такие неравенства по итерациям от $i = 0$ до $k$. Правая часть свернется в телескопическую сумму:

$$\frac{1}{2L}\sum_{i=0}^{k}\|\nabla\varphi(y_i)\|^2 \leqslant \varphi(y_0) - \varphi(y_{k+1}) \leqslant \varphi(y_0) - \varphi^* \tag{20}$$

где $\varphi^*$ — оптимальное (минимальное) значение функции.

Чтобы оценить скорость сходимости по градиенту, ограничим сумму через её минимальный элемент:

$$(k+1) \cdot \min_{0 \leqslant i \leqslant k} \|\nabla \varphi(y_i)\|^2 \leqslant \sum_{i=0}^{k} \|\nabla \varphi(y_i)\|^2 \leqslant 2L(\varphi(y_0) - \varphi^*) \tag{21}$$

Откуда:

$$\min_{0 \leqslant i \leqslant k} \|\nabla \varphi(y_i)\| \leqslant \sqrt{\frac{2L(\varphi(y_0) - \varphi^*)}{k+1}} = O\left(\frac{L}{\sqrt{k}}\right) \tag{22}$$

Вспомним, что норма градиента двойственной функции в точности равна невязке ограничений прямой транспортной задачи. Чтобы достичь требуемой точности решения $\varepsilon$, алгоритму потребуется:

$$\frac{L}{\sqrt{k}} \approx \varepsilon \implies k = O\left(\frac{L}{\varepsilon^2}\right) \text{ итераций.}$$

Такая скорость является очень медленной для применения на практике, особенно при решении задач оптимального транспорта больших размерностей, требующих высокой точности. Это обосновывает необходимость применения других методов.

Напоследок скажем пару слов про скорость убывания самой функции. Так как наша двойственная функция $\varphi(y)$ является выпуклой, а её градиент удовлетворяет условию Липшица с константой $L$, для градиентного спуска с шагом $\eta = \frac{1}{L}$ справедлива следующая оценка сходимости по значению функции:

$$\varphi(y_k) - \varphi^* = O\left(\frac{1}{k}\right) \tag{23}$$

Однако в контексте прямо-двойственного подхода к задаче оптимального транспорта нас интересует в первую очередь не значение двойственной функции $\varphi(y)$, а выполнение ограничений прямой задачи. Поэтому критически важной является именно оценка на убывание нормы градиента.

## Ускоренный градиентный спуск

Рассмотрим ускоренный градиентый спуск(придуманный Нестеровым) для решения задачи оптимального транспорта. В отличие от обычного градиентного спуска, который использует только текущую точку, метод Нестерова вводит дополнительную последова-

тельность точек $\{v_k\}$, использующую «инерцию» (вектор прошлого перемещения):

$$v_k = y_k + \frac{k-1}{k+2}(y_k - y_{k-1})$$
$$y_{k+1} = v_k - \frac{1}{L}\nabla\varphi(v_k)$$

Теорема Нестерова гарантирует, что для выпуклых функций, которые обладают липшицевостью градиента, значение самой функции убывает как:

$$\varphi(y_k) - \varphi^* \leqslant \frac{CL}{k^2} \tag{24}$$

Однако есть проблема: в классическом методе Нестерова норма градиента убывает немонотонно и может сильно осциллировать. Следовательно, мы не можем просто взять точку $y_k$ и сказать, что план $x(y_k)$ будет хорошим.

## Primal-Dual подход

Чтобы решить проблему немонотонного убывания градиента (которая в нашей задаче означает невязку ограничений), применяется прямо-двойственный подход. Именно это делается в статье П. Двуреченского, А. Гасникова и А. Крошнина[1].

Главная идея авторов заключается в том, чтобы не брать транспортный план из последней точки, а строить усредненный план из всех предыдущих итераций алгоритма. Пусть на каждой итерации $i$ алгоритм генерирует веса $\alpha_i > 0$. Обозначим $A_k = \sum_{i=0}^{k} \alpha_i$. В ускоренных методах параметры подбираются так, что $A_k = \mathcal{O}(k^2/L)$. Определим усредненный транспортный план $\hat{x}_k$ как комбинацию:

$$\hat{x}_k = \frac{1}{A_k}\sum_{i=0}^{k} \alpha_i x(w_i) \tag{25}$$

где $w_i$ — точки экстраполяции, в которых алгоритм вычисляет градиенты. Ниже приведем анализ убывания невязки для этого усредненного плана, который является фундаментом для доказательства главной теоремы статьи. Известно, что генерируемая ускоренным методом последовательность удовлетворяет следующему базовому энергетическому неравенству для любого вектора $z$:

$$A_k\varphi(y_k) \leqslant \frac{1}{2}\|z - y_0\|^2 + \sum_{i=0}^{k} \alpha_i\Big(\varphi(w_i) + \langle\nabla\varphi(w_i), z - w_i\rangle\Big) \tag{26}$$

[1] https://proceedings.mlr.press/v80/dvurechensky18a/dvurechensky18a.pdf

Пусть $y^*$ — точка глобального минимума двойственной функции. Прибавим и вычтем $y^*$ внутри скалярного произведения:

$$\varphi(w_i) + \langle \nabla\varphi(w_i), z - w_i \rangle = \varphi(w_i) + \langle \nabla\varphi(w_i), y^* - w_i \rangle + \langle \nabla\varphi(w_i), z - y^* \rangle$$

Поскольку функция $\varphi$ выпукла, то: $\varphi(w_i) + \langle \nabla\varphi(w_i), y^* - w_i \rangle \leqslant \varphi(y^*)$. Подставляя это в сумму и вынося независящие от $i$ члены, получаем:

$$A_k\varphi(y_k) \leqslant \frac{1}{2}\|z - y_0\|^2 + \varphi(y^*)\sum_{i=0}^{k}\alpha_i + \left\langle \sum_{i=0}^{k}\alpha_i\nabla\varphi(w_i),\, z - y^* \right\rangle$$

Учитывая, что $\sum_{i=0}^{k}\alpha_i = A_k$, перенесем $A_k\varphi(y^*)$ в левую часть:

$$A_k\big(\varphi(y_k) - \varphi(y^*)\big) \leqslant \frac{1}{2}\|z - y_0\|^2 + \left\langle \sum_{i=0}^{k}\alpha_i\nabla\varphi(w_i),\, z - y^* \right\rangle \tag{27}$$

Левая часть неотрицательна, так как $y^*$ — минимум. Преобразуем сумму градиентов, используя прямо-двойственную связь $\nabla\varphi(w_i) = b - Ax(w_i)$:

$$\sum_{i=0}^{k}\alpha_i\nabla\varphi(w_i) = \sum_{i=0}^{k}\alpha_i\big(b - Ax(w_i)\big) = A_k b - A\left(\sum_{i=0}^{k}\alpha_i x(w_i)\right) = A_k\big(b - A\hat{x}_k\big)$$

Обозначим вектор невязки усредненного плана как $R_k = b - A\hat{x}_k$. Тогда неравенство (27) упрощается до:

$$0 \leqslant \frac{1}{2}\|z - y_0\|^2 + A_k\langle R_k, z - y^* \rangle \tag{28}$$

Чтобы получить оценку на $\|R_k\|$, выберем $z = y_0 - \lambda R_k$ для некоторого $\lambda > 0$. Тогда $\|z - y_0\|^2 = \lambda^2\|R_k\|^2$, а $z - y^* = (y_0 - y^*) - \lambda R_k$. Подставляя это в (28) и группируя слагаемые с $\|R_k\|^2$, имеем:

$$\left(A_k\lambda - \frac{1}{2}\lambda^2\right)\|R_k\|^2 \leqslant A_k\langle R_k, y_0 - y^* \rangle \tag{29}$$

Применим неравенство КБШ к правой части. Обозначив $D = \|y_0 - y^*\|$ и сократив на $\|R_k\|$, получим:

$$\left(A_k\lambda - \frac{1}{2}\lambda^2\right)\|R_k\| \leqslant A_k D \tag{30}$$

Максимум параболы в скобках по $\lambda$ достигается при $\lambda = A_k$. Подставляя оптимальное $\lambda$,

приходим к строгому ограничению на невязку:

$$\frac{1}{2}A_k^2\|R_k\| \leqslant A_k D \implies \|b - A\hat{x}_k\| \leqslant \frac{2D}{A_k} = \mathcal{O}\left(\frac{L}{k^2}\right) \tag{31}$$

## Итоговая сложность

Из полученной оценки $\|R_k\| \leqslant \mathcal{O}(L/k^2)$ следует, что для достижения требуемой точности по невязке ($\|R_k\| \leqslant \varepsilon$) алгоритму потребуется следующее число итераций:

$$\frac{L}{k^2} \leqslant \varepsilon \implies k = \mathcal{O}\left(\sqrt{\frac{L}{\varepsilon}}\right) \tag{32}$$

Возникает естественный вопрос: почему бы не взять $\gamma$ очень большим, чтобы константа Липшица $L \sim 1/\gamma$ стала маленькой, и алгоритм сошелся бы почти мгновенно?

Вспомним, что наша глобальная цель — найти $\varepsilon$-приближенное решение не просто для сглаженной задачи, а для исходной (нерегуляризованной) транспортной задачи. Пусть $f(x) = \langle C, x\rangle$ — целевая функция стоимости перевозок исходной задачи, а $f_\gamma(x) = f(x) + \gamma H(x)$ — регуляризованная функция. Пусть $x^*$ — точный оптимальный план исходной задачи, а $x_\gamma^*$ — оптимальный план регуляризованной задачи.

Поскольку $x_\gamma^*$ минимизирует функцию $f_\gamma$, справедливо неравенство $f_\gamma(x_\gamma^*) \leqslant f_\gamma(x^*)$, то есть:

$$f(x_\gamma^*) + \gamma H(x_\gamma^*) \leqslant f(x^*) + \gamma H(x^*) \tag{33}$$

Перегруппируем слагаемые:

$$f(x_\gamma^*) - f(x^*) \leqslant \gamma\big(H(x^*) - H(x_\gamma^*)\big) \tag{34}$$

Так как значения энтропии на множестве допустимых планов ограничены некоторой константой $D_H$, получаем:

$$f(x_\gamma^*) - f(x^*) \leqslant \gamma D_H \tag{35}$$

Это неравенство доказывает ключевой факт: чтобы найденный план отличался от идеального по стоимости не более чем на $\varepsilon$, необходимо выбирать параметр регуляризации пропорциональным требуемой точности: $\gamma = \mathcal{O}(\varepsilon)$. Тогда:

$$L \sim \frac{1}{\varepsilon} \tag{36}$$

Подставим эту зависимость $L$ от $\varepsilon$ обратно в формулу для числа итераций (32):

$$k = \mathcal{O}\left(\sqrt{\frac{1/\varepsilon}{\varepsilon}}\right) = \mathcal{O}\left(\sqrt{\frac{1}{\varepsilon^2}}\right) = \mathcal{O}\left(\frac{1}{\varepsilon}\right) \tag{37}$$

На каждой итерации ускоренного прямо-двойственного метода необходимо вычислять градиент, что сводится к умножению матрицы транспортных стоимостей на вектор. Для задачи с $n$ источниками и $n$ потребителями это требует $\mathcal{O}(n^2)$ арифметических операций.

Таким образом, итоговая вычислительная сложность алгоритма составляет $\mathcal{O}\left(\frac{n^2}{\varepsilon}\right)$. Полученный результат показывает качественное превосходство ускоренного метода.

**Замечание о скрытых константах и точной оценке сложности**

Полученная нами ранее оценка $\mathcal{O}(n^2/\varepsilon)$ верно отражает зависимость алгоритма от требуемой точности $\varepsilon$. Однако в статье Двуреченского заявлена оценка $\mathcal{O}\left(\frac{n^{9/4}}{\varepsilon}\right)$. Покажем эту оценку, опираясь на выведенную нами формулу (31).

$$\|b - A\hat{x}_k\| \leqslant \frac{2D}{A_k} \tag{38}$$

Поскольку в ускоренном методе Нестерова веса подбираются так, что $A_k = \mathcal{O}(k^2/L)$, перепишем условие достижения точности $\varepsilon$:

$$\frac{L \cdot D}{k^2} \leqslant \varepsilon \implies k = \mathcal{O}\left(\sqrt{\frac{L \cdot D}{\varepsilon}}\right) \tag{39}$$

Здесь $D = \|y_0 - y^*\|$ — это расстояние от стартовой точки до оптимального вектора двойственных переменных. Ранее мы считали $D$ константой. Однако вектор $y$ имеет размерность $2n$ (считаем, что у нас $n$ источников и $n$ потребителей).

Если мы вычисляем обычную (Евклидову) длину вектора размерности $2n$, координаты которого ограничены константой, то его длина растет пропорционально корню из размерности. Следовательно, расстояние до оптимума зависит от $n$ как:

$$D = \mathcal{O}(\sqrt{n}) \tag{40}$$

Подставим зависимости $D$ и $L$ в формулу числа итераций (39):

$$k = \mathcal{O}\left(\sqrt{\frac{(1/\varepsilon) \cdot \sqrt{n}}{\varepsilon}}\right) = \mathcal{O}\left(\sqrt{\frac{\sqrt{n}}{\varepsilon^2}}\right) = \mathcal{O}\left(\frac{n^{1/4}}{\varepsilon}\right) \tag{41}$$

Получаем финальную теоретическую сложность $\mathcal{O}\left(\frac{n^{9/4}}{\varepsilon}\right)$

# Метод Ньютона

Ранее мы рассматривали методы первого порядка. Естественным развитием является переход к методам второго порядка.

Однако применение классического метода Ньютона к энтропийно-регуляризованной задаче оптимального транспорта сталкивается с проблемой вырожденности матриц. Ниже мы разберем суть этой проблемы и способ её решения, опираясь на работу Ю. Нестерова и Б. Поляка (2006)[2].

## Проблема классического метода Ньютона

Классический метод Ньютона ищет оптимальный шаг $h$, минимизируя квадратичное приближение Тейлора:

$$\varphi(y_k + h) \approx \varphi(y_k) + \langle \nabla\varphi(y_k), h\rangle + \frac{1}{2}\langle \nabla^2\varphi(y_k)h, h\rangle \tag{42}$$

Приравнивая градиент по $h$ к нулю, получаем:

$$\nabla^2\varphi(y_k)h = -\nabla\varphi(y_k) \tag{43}$$

Для нахождения шага $h$ необходимо обратить матрицу Гессе $\nabla^2\varphi(y_k)$. Однако, как было показано ранее, в задаче оптимального транспорта Гессиан лишь неотрицательно определен и имеет нулевые собственные значения. Из-за вырожденности матрицы прямое обращение невозможно, и классический метод Ньютона плохо применим.

## Метод кубического Ньютона

Пусть Гессиан удовлетворяет условию Липшица с константой $M > 0$:

$$\|\nabla^2\varphi(y + h) - \nabla^2\varphi(y)\| \leqslant M\|h\| \quad \forall y, h \tag{44}$$

Для нашей функции $\varphi(y)$ это условие выполняется. Приращение функции можно представить как:

$$\varphi(y_k + h) = \varphi(y_k) + \langle \nabla\varphi(y_k), h\rangle + \int_0^1 (1-\tau)\langle \nabla^2\varphi(y_k + \tau h)h, h\rangle\, d\tau \tag{45}$$

Прибавляя и вычитая $\nabla^2\varphi(y_k)$ под интегралом и применяя неравенство КБШ вместе с условием Липшица, мы получаем строгую глобальную верхнюю оценку - кубическую ма-

[2] https://link.springer.com/article/10.1007/s10107-006-0706-8

жоранту:

$$\varphi(y_k + h) \leqslant \varphi(y_k) + \langle \nabla\varphi(y_k), h\rangle + \frac{1}{2}\langle \nabla^2\varphi(y_k)h, h\rangle + \frac{M}{6}\|h\|^3 \tag{46}$$

На каждом шаге метод минимизирует кубическую мажоранту. Приравняв её градиент по вектору $h$ к нулю и обозначив $g_k = \nabla\varphi(y_k)$, $H_k = \nabla^2\varphi(y_k)$, получаем модифицированную систему:

$$\left(H_k + \frac{M}{2}\|h_k\|I\right) h_k = -g_k \tag{47}$$

Заметим, что это уравнение решает нашу прошлую проблему. В результате матрица системы становится строго положительно определенной и становится обратимой.

Докажем, что на каждой итерации функция гарантированно убывает пропорционально кубу длины шага.

**Лемма.** $\varphi(y_{k+1}) \leqslant \varphi(y_k) - \frac{M}{3}\|h_k\|^3$.

*Доказательство.* Выразив $g_k$ из (47), вычислим скалярное произведение: $\langle g_k, h_k\rangle = -\langle H_k h_k, h_k\rangle - \frac{M}{2}\|h_k\|^3$. Подставим это выражение обратно в (46):

$$\varphi(y_{k+1}) \leqslant \varphi(y_k) - \frac{1}{2}\langle H_k h_k, h_k\rangle - \frac{M}{3}\|h_k\|^3 \tag{48}$$

Поскольку матрица $H_k \succeq 0$, квадратичная форма неотрицательна. Следовательно, мы можем отбросить слагаемое $-\frac{1}{2}\langle H_k h_k, h_k\rangle$, усилив неравенство:

$$\varphi(y_{k+1}) \leqslant \varphi(y_k) - \frac{M}{3}\|h_k\|^3 \tag{49}$$

□

В задаче оптимального транспорта нас прежде всего интересует скорость падения нормы градиента $\|\nabla\varphi(y)\|$.

Запишем приращение градиента в новой точке $y_{k+1} = y_k + h_k$:

$$\nabla\varphi(y_{k+1}) = \underbrace{\nabla\varphi(y_k) + \nabla^2\varphi(y_k)h_k}_{=-\frac{M}{2}\|h_k\|h_k \text{ из } (47)} + \int_0^1 (\nabla^2\varphi(y_k + \tau h_k) - \nabla^2\varphi(y_k))h_k\, d\tau \tag{50}$$

Беря норму обеих частей и используя условие Липшица, получаем:

$$\|\nabla\varphi(y_{k+1})\| \leqslant \frac{M}{2}\|h_k\|^2 + \int_0^1 M\tau\|h_k\|^2\, d\tau = M\|h_k\|^2 \tag{51}$$

Отсюда выражаем длину шага: $\|h_k\| \geqslant \sqrt{\|\nabla\varphi(y_{k+1})\|/M}$. Подставляя это в Лемму (49) и

суммируя телескопическую сумму по $N$ итерациям, имеем:

$$\varphi(y_0) - \varphi^* \geqslant \sum_{i=1}^{N} \frac{1}{3\sqrt{M}} \|\nabla\varphi(y_i)\|^{3/2} \geqslant \frac{N}{3\sqrt{M}} \min_{1\leqslant i\leqslant N} \|\nabla\varphi(y_i)\|^{3/2} \tag{52}$$

Разрешая относительно нормы градиента, получаем итоговую скорость сходимости метода:

$$\min_{1\leqslant i\leqslant N} \|\nabla\varphi(y_i)\| \leqslant \left(\frac{3\sqrt{M}(\varphi(y_0) - \varphi^*)}{N}\right)^{2/3} = \mathcal{O}\left(\frac{1}{N^{2/3}}\right) \tag{53}$$

## Итоговая сложность

Чтобы достичь требуемой точности по невязке $\|\nabla\varphi(y)\| \leqslant \varepsilon$, алгоритму потребуется следующее число итераций:

$$N = \mathcal{O}\left(\frac{\sqrt{M}}{\varepsilon^{1.5}}\right) \tag{54}$$

Вспомним специфику нашей задачи. Как было показано ранее параметр $\gamma$ нужно выбирать как $\gamma = \mathcal{O}(\varepsilon)$. При этом матрица Гессе содержит множитель $\frac{1}{\gamma}$, а третья производная выдает в знаменатель еще одну $\gamma$. Следовательно, константа Липшица $M$ растет как $M = \mathcal{O}\left(\frac{1}{\gamma^2}\right) = \mathcal{O}\left(\frac{1}{\varepsilon^2}\right)$. Получаем:

$$N = \mathcal{O}\left(\frac{1}{\varepsilon^{2.5}}\right) \tag{55}$$

На каждой из $N$ итераций необходимо решать модифицированную СЛАУ (47) размера $(2n \times 2n)$ (для $n$ поставщиков и $n$ потребителей). Решение такой системы требует $\mathcal{O}(n^3)$. Таким образом, финальная вычислительная сложность применения Кубического Ньютона к задаче оптимального транспорта составляет:

$$\mathcal{O}\left(\frac{n^3}{\varepsilon^{2.5}}\right) \tag{56}$$

Сравнив этот результат со сложностью $\mathcal{O}\left(\frac{n^{2.25}}{\varepsilon}\right)$ ускоренного градиентного спуска (Primal-Dual подхода), мы приходим к важному заключению. Несмотря на лучшую теоретическую скорость сходимости по числу итераций ($\mathcal{O}(N^{-2/3})$ против $\mathcal{O}(N^{-2})$), метод второго порядка для энтропийно-регуляризованной задачи оптимального транспорта проигрывает. Это происходит из-за двух факторов: высокой стоимости одной итерации (обращение матрицы $\mathcal{O}(n^3)$) и взрыва константы Липшица при малых значениях параметра регуляризации $\gamma$.

# Эксперименты

Программная реализация описанных методов первого и второго порядка, а также результаты численных экспериментов вынесены в отдельный Jupyter-ноутбук. На примере синтетической одномерной задачи оптимального транспорта проведено эмпирическое сравнение алгоритмов и наглядно продемонстрирована эффективность прямо-двойственного подхода.

Ознакомиться с исходным кодом можно в репозитории на GitHub: `experiments.ipynb`[3].

# Современные методы второго порядка

В данном разделе рассматривается переход от классической реализации метода Ньютона к оптимизированному алгоритму, адаптированному под структуру задачи энтропийного оптимального транспорта. Представленные далее рассуждения и выкладки опираются на работы neurips2024[4] и openreview2024[5].

## Преодоление вычислительной сложности: структура Гессиана

Вспомним, что в нашей модели $n$ источников и $m$ потребителей. Ограничения транспортной задачи (законы сохранения) состоят из $n + m$ уравнений.

Переменные исходной задачи вытянуты в вектор $x \in \mathbb{R}^N$, где общая размерность $N = nm$. Для перехода от двумерной сетки к одномерному вектору введем связь индексов. Пусть $i \in \{1, \ldots, n\}$ — индекс источника, а $j \in \{1, \ldots, m\}$ — индекс потребителя. Тогда каждому ребру двудольного графа (маршруту от $i$ к $j$) можно однозначно сопоставить одномерный индекс $k \in \{1, \ldots, N\}$:

$$k = (i - 1)m + j \tag{57}$$

Матрица инцидентности $A \in \mathbb{R}^{(n+m)\times N}$ превращает систему ограничений в линейное уравнение $Ax = b$. Поскольку ограничения естественно разбиваются на две группы (для источников и для потребителей), разрежем матрицу $A$ на два горизонтальных блока:

$$A = \begin{pmatrix} A_1 \\ A_2 \end{pmatrix} \tag{58}$$

[3] Прямая ссылка на код: `https://github.com/ilapodsvetov/optimal-transport-optimization/blob/main/experiments.ipynb`

[4] `https://papers.nips.cc/paper/2024/file/ea8620683340facbd5f754dd169e0980-Paper-Conference.pdf`

[5] `https://openreview.net/pdf?id=WCkMkMcqpb`

где $A_1 \in \mathbb{R}^{n\times N}$ отвечает за источники, а $A_2 \in \mathbb{R}^{m\times N}$ — за потребителей.

Аналогично, вектор двойственных переменных $y \in \mathbb{R}^{n+m}$ разобьем на два вектора:

$$y = \begin{pmatrix} u \\ v \end{pmatrix} \tag{59}$$

где $u \in \mathbb{R}^n$ — двойственные потенциалы источников, а $v \in \mathbb{R}^m$ — двойственные потенциалы потребителей.

Вычислим вектор $A^T y \in \mathbb{R}^N$:

$$A^T y = \begin{pmatrix} A_1^T & A_2^T \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix} = A_1^T u + A_2^T v \tag{60}$$

Рассмотрим $k$-ю координату этого вектора, где индекс $k$ соответствует паре $(i, j)$. В $k$-й строке матрицы $A_1^T$ единица стоит только на $i$-й позиции, поэтому $(A_1^T u)_k = u_i$. Аналогично, в $k$-й строке $A_2^T$ единица стоит только на $j$-й позиции, откуда $(A_2^T v)_k = v_j$. Таким образом, мы получаем:

$$(A^T y)_k = u_i + v_j \tag{61}$$

Перепишем двойственную функцию $\varphi(y)$ через векторы $u$ и $v$, заменив одномерную сумму по $k$ на двойную сумму по $i$ и $j$. Обозначим $b = \begin{pmatrix} O \\ D \end{pmatrix}$, тогда:

$$\varphi(u, v) = \langle u, O\rangle + \langle v, D\rangle + \gamma \sum_{i=1}^{n} \sum_{j=1}^{m} \exp\left(-\frac{c_{ij} + u_i + v_j}{\gamma}\right) \tag{62}$$

Для удобства обозначим элементы нашей транспортной матрицы $X(u, v) \in \mathbb{R}^{n\times m}$ как:

$$X_{ij} = \exp\left(-\frac{c_{ij} + u_i + v_j}{\gamma}\right) \tag{63}$$

Найдем частные производные по $u_i$:

$$\frac{\partial \varphi}{\partial u_i} = O_i + \gamma \sum_{j=1}^{m} X_{ij} \cdot \left(-\frac{1}{\gamma}\right) = O_i - \sum_{j=1}^{m} X_{ij} \tag{64}$$

В матричном виде градиент по блокам $u$ и $v$ записывается так:

$$\nabla \varphi(y) = \begin{pmatrix} \nabla_u \varphi \\ \nabla_v \varphi \end{pmatrix} = \begin{pmatrix} O - X\mathbf{1}_m \\ D - X^T \mathbf{1}_n \end{pmatrix} \tag{65}$$

где $\mathbf{1}_m$ и $\mathbf{1}_n$ — векторы из единиц соответствующей длины.

Теперь вычислим Гессиан. Он разбивается на 4 блока:

$$\nabla^2\varphi(u,v) = \begin{pmatrix} \nabla^2_{uu}\varphi & \nabla^2_{uv}\varphi \\ \nabla^2_{vu}\varphi & \nabla^2_{vv}\varphi \end{pmatrix} \tag{66}$$

Дифференцируя $\frac{\partial\varphi}{\partial u_i}$ по $u_l$, заметим, что производная отлична от нуля только при $i = l$. Значит, блок $\nabla^2_{uu}\varphi$ является диагональной матрицей. Обозначим ее $\frac{1}{\gamma}D_1$, где $D_1 = \mathrm{diag}(X\mathbf{1}_m)$. Аналогично, блок $\nabla^2_{vv}\varphi$ — это диагональная матрица $\frac{1}{\gamma}D_2$, где $D_2 = \mathrm{diag}(X^T\mathbf{1}_n)$.

Для смешанного блока продифференцируем $\frac{\partial\varphi}{\partial u_i}$ по $v_l$. В сумме выживет только одно слагаемое $X_{il}$, откуда $\frac{\partial^2\varphi}{\partial u_i \partial v_l} = \frac{1}{\gamma}X_{il}$. Это означает, что матрица смешанных производных в точности равна $\frac{1}{\gamma}X$.

Итоговый строгий вид матрицы Гессе:

$$\nabla^2\varphi(u,v) = \frac{1}{\gamma}\begin{pmatrix} D_1 & X \\ X^T & D_2 \end{pmatrix} \tag{67}$$

Метод Ньютона ищет вектор приращений $\Delta y = (\Delta u, \Delta v)^T$, решая систему:

$$\nabla^2\varphi(y)\begin{pmatrix} \Delta u \\ \Delta v \end{pmatrix} = -\nabla\varphi(y) \tag{68}$$

Перенесем множитель $\frac{1}{\gamma}$ вправо, обозначив новые правые части как $g_u = -\gamma\nabla_u\varphi$ и $g_v = -\gamma\nabla_v\varphi$. Распишем СЛАУ как систему двух уравнений:

$$D_1\Delta u + X\Delta v = g_u \tag{69}$$

$$X^T\Delta u + D_2\Delta v = g_v \tag{70}$$

Ключевой шаг состоит в аналитическом исключении части переменных. Так как матрица $D_2$ диагональна, ее обращение тривиально и требует всего $\mathcal{O}(m)$ операций (элементы обратной матрицы — это просто $1/(D_2)_{jj}$). Из уравнения (70) выразим $\Delta v$:

$$\Delta v = D_2^{-1}(g_v - X^T\Delta u) \tag{71}$$

Подставим полученное выражение в уравнение (69):

$$D_1\Delta u + X\left(D_2^{-1}(g_v - X^T\Delta u)\right) = g_u \tag{72}$$

Раскроем скобки и сгруппируем слагаемые при $\Delta u$:

$$(D_1 - XD_2^{-1}X^T)\Delta u = g_u - XD_2^{-1}g_v \tag{73}$$

Матрица $S = D_1 - XD_2^{-1}X^T$ называется Дополнением Шура блока $D_2$. Теперь размерность нашей СЛАУ (73) уменьшилась с $(n+m)$ до $n \times n$.

Однако, если мы попытаемся явно вычислить матрицу $S$ , а затем обратить её стандартными прямыми методами, то итерация по-прежнему будет иметь кубическую сложность.

Прорыв заключается в использовании итерационного метода Сопряженных Градиентов (Conjugate Gradients, CG). Для применения этого метода матрица системы должна быть симметричной и положительно определенной (несложно убедиться, что для $S$ это выполняется).

Главное преимущество метода CG состоит в том, что ему не требуется матрица $S$ в явном виде. На каждой итерации алгоритму требуется только уметь вычислять произведение матрицы $S$ на некоторый заданный вектор $w \in \mathbb{R}^n$.

Давайте проанализируем вычислительную сложность вычисления вектора $p = Sw$:

$$p = (D_1 - XD_2^{-1}X^T)w = D_1 w - X\left(D_2^{-1}(X^T w)\right) \tag{74}$$

1. $q_1 = X^T w$ — умножение матрицы $m \times n$ на вектор $n \times 1$. Требует $\mathcal{O}(nm)$ операций.

2. $q_2 = D_2^{-1} q_1$ — поэлементное умножение диагональной матрицы на вектор. Требует $\mathcal{O}(m)$ операций.

3. $q_3 = Xq_2$ — умножение матрицы $n \times m$ на вектор $m \times 1$. Требует $\mathcal{O}(nm)$ операций.

4. $q_4 = D_1 w$ — поэлементное умножение. Требует $\mathcal{O}(n)$ операций.

5. $p = q_4 - q_3$ — сложение векторов за $\mathcal{O}(n)$ операций.

Одно матрично-векторное умножение $Sw$ требует всего $\mathcal{O}(nm)$ операций. Предполагая, что $n \approx m$, сложность составляет $\mathcal{O}(n^2)$. Авторы современных статей доказывают, что для задачи энтропийного оптимального транспорта матрица $S$ "хорошая". Благодаря этому, метод CG сходится до требуемой точности за крайне малое количество итераций, которое практически не зависит от размерности задачи. Таким образом, количество шагов CG можно считать константой $\mathcal{O}(1)$.

Итоговая сложность решения уменьшенной СЛАУ составляет $\mathcal{O}(n^2) \cdot \mathcal{O}(1) = \mathcal{O}(n^2)$. Найдя $\Delta u$, мы за $\mathcal{O}(n^2)$ восстанавливаем $\Delta v$ по формуле (71). Мы можем делать полный шаг Ньютона за квадратичное время вместо кубического.

Одна из проблем метода Ньютона решена. Однако остается проблема — условие Липшица для Гессиана, из-за которого метод все еще требует огромного числа внешних итераций.

## Локальная метрика и проблема вырожденности (полунорма)

Главная проблема метода второго порядка для нашей задачи кроется в оценке длины шага. Ранее мы показали, что матрица Гессе $\nabla^2\varphi(y)$ удовлетворяет условию Липшица в стандартной Евклидовой норме с константой $M \sim \frac{1}{\gamma^2}$. При малых значениях параметра регуляризации $\gamma$ (что необходимо для высокой точности) константа $M$ устремляется к бесконечности. Это заставляет алгоритм делать микроскопические шаги, что приводит к медленной теоретической сходимости $\mathcal{O}(\varepsilon^{-2.5})$.

Чтобы избавиться от зависимости от глобальной константы $M$, откажемся от стандартной Евклидовой метрики. Введем локальную меру длины, порожденную самим Гессианом в текущей точке $y$:

$$\|h\|_y = \sqrt{\langle \nabla^2\varphi(y)h, h\rangle} \tag{75}$$

Здесь возникает некоторая математическая проблема. Поскольку Гессиан $\nabla^2\varphi(y)$ в нашей задаче вырожден, выражение (75) задает не строгую норму, а полунорму. То есть существует ненулевой вектор $h \neq 0$, длина которого в этой метрике равна нулю: $\|h\|_y = 0$.

В общем случае оптимизация в полунорме невозможна: алгоритм может сделать огромный шаг в направлении ядра матрицы, локальная длина шага будет равна нулю, а значение функции непредсказуемо изменится. Докажем, что в нашей задаче эта вырожденность безопасна.

Вектор переменных состоит из двух блоков: $y = (u, v)^T \in \mathbb{R}^{n+m}$. Значение двойственной функции $\varphi(y)$ зависит исключительно от сумм $(u_i + v_j)$. Если прибавить ко всем $u_i$ константу $c$ и вычтем ее из всех $v_j$, аргументы экспонент не изменятся: $(u_i + c) + (v_j - c) = u_i + v_j$. Значит, вектор сдвига $e_{ker} = (\mathbf{1}_n, -\mathbf{1}_m)^T$ лежит в ядре Гессиана: $\nabla^2\varphi(y)e_{ker} = 0$, и $\|e_{ker}\|_y = 0$. Однако смещение вдоль этого вектора оставляет значение функции тождественно равным:

$$\varphi(y + c \cdot e_{ker}) \equiv \varphi(y), \quad \forall c \in \mathbb{R} \tag{76}$$

Поскольку в направлении ядра функция плоская, нулевая длина шага $\|e_{ker}\|_y = 0$ оправдана.

## Шаг Ньютона и декремент

Направление шага Ньютона $h_N$ ищется как решение системы линейных уравнений:

$$\nabla^2\varphi(y)h_N = -\nabla\varphi(y) \tag{77}$$

Введем важную характеристику метода — декремент Ньютона $\lambda(y)$. Это длина вектора шага Ньютона, измеренная в нашей новой локальной метрике:

$$\lambda(y) \equiv \|h_N\|_y = \sqrt{\langle \nabla^2 \varphi(y) h_N, h_N \rangle} \tag{78}$$

Подставляя уравнение (77) в скалярное произведение, получаем:

$$\lambda^2(y) = \langle -\nabla \varphi(y), h_N \rangle \tag{79}$$

Декремент $\lambda(y)$ — это мера близости к локальному минимуму. Если $\lambda(y) = 0$, значит мы достигли оптимума (градиент равен нулю).

## Самосогласованность

При смещении из точки $y$ Гессиан меняется, а значит, искажается и наша локальная метрика. Для контроля этого искажения Ю. Нестеровым была введена концепция самосогласованности (Self-Concordance).

Для функции двойственной задачи, состоящей из экспонент, доказывается фундаментальное неравенство самосогласованности:

$$|\nabla^3 \varphi(y)[h, h, h]| \leqslant 2\|h\|_y^3 \tag{80}$$

где $\nabla^3 \varphi(y)[h, h, h] = \frac{d^3}{dt^3} \varphi(y + th)\Big|_{t=0}$

Это неравенство принципиально отличается от условия Липшица: в нем нет внешних констант (вроде $M$, зависящей от $\gamma$).

## Вывод мажоранты

Покажем математически строго, как из (80) выводится оценка на длину шага. Рассмотрим одномерное сечение нашей функции вдоль направления $h_N$. Пусть $t \geqslant 0$:

$$\varphi(t) = \varphi(y + t h_N) \tag{81}$$

Вычислим производные $\varphi(t)$ в нуле ($t = 0$), опираясь на свойства декремента (78) и (79):

$$\varphi'(0) = \langle \nabla \varphi(y), h_N \rangle = -\lambda^2 \tag{82}$$

$$\varphi''(0) = \langle \nabla^2 \varphi(y) h_N, h_N \rangle = \|h_N\|_y^2 = \lambda^2 \tag{83}$$

Заметим, что по определению $\varphi'''(t) = \nabla^3\varphi(y+th_N)[h_N, h_N, h_N]$ и $\varphi''(t) = \|h_N\|^2_{y+th_N}$. Тогда из условия самосогласованности (80) вытекает дифференциальное неравенство для $\varphi(t)$:

$$\varphi'''(t) \leqslant 2(\varphi''(t))^{3/2} \tag{84}$$

Разделим переменные и проинтегрируем обе части от 0 до $t$:

$$\int_0^t \frac{\varphi'''(\tau)}{(\varphi''(\tau))^{3/2}}\,d\tau \leqslant \int_0^t 2\,d\tau \implies -2(\varphi''(\tau))^{-1/2}\Big|_0^t \leqslant 2t \tag{85}$$

Подставим $\varphi''(0) = \lambda^2$ и разделим на 2:

$$\frac{1}{\lambda} - \frac{1}{\sqrt{\varphi''(t)}} \leqslant t \implies \frac{1}{\sqrt{\varphi''(t)}} \geqslant \frac{1-t\lambda}{\lambda} \tag{86}$$

При условии $t < 1/\lambda$ правая часть строго положительна. Возводя неравенство в минус вторую степень, получаем оценку на вторую производную вдоль направления шага:

$$\varphi''(t) \leqslant \frac{\lambda^2}{(1-t\lambda)^2} \tag{87}$$

Проинтегрируем это неравенство еще раз от 0 до $t$, чтобы оценить первую производную:

$$\varphi'(t) - \varphi'(0) \leqslant \int_0^t \frac{\lambda^2}{(1-\tau\lambda)^2}\,d\tau = \frac{\lambda}{1-\tau\lambda}\Big|_0^t = \frac{\lambda}{1-t\lambda} - \lambda \tag{88}$$

Вспоминая, что $\varphi'(0) = -\lambda^2$, переносим это значение вправо:

$$\varphi'(t) \leqslant -\lambda^2 - \lambda + \frac{\lambda}{1-t\lambda} \tag{89}$$

Наконец, интегрируем в третий раз на отрезке от 0 до итогового размера шага $\alpha$:

$$\varphi(\alpha) - \varphi(0) \leqslant \int_0^\alpha \left(-\lambda^2 - \lambda + \frac{\lambda}{1-t\lambda}\right) dt = -\alpha\lambda^2 - \alpha\lambda - \ln(1-\alpha\lambda) \tag{90}$$

Возвращаясь к многомерным обозначениям $\varphi(y + \alpha h_N) = \varphi(\alpha)$, мы получаем точную аналитическую мажоранту Нестерова, которая заменяет нам кубическую аппроксимацию:

$$\varphi(y + \alpha h_N) \leqslant \varphi(y) - \alpha\lambda^2 - \alpha\lambda - \ln(1-\alpha\lambda) \tag{91}$$

## Демпфированный шаг Ньютона и итоговая сложность

Теперь нам достаточно найти длину скалярного шага $\alpha$, минимизирующую правую часть мажоранты (91). Приравняем производную по $\alpha$ к нулю:

$$-\lambda^2 - \lambda + \frac{\lambda^2}{1-\alpha\lambda} = 0 \implies \frac{\lambda}{1-\alpha\lambda} = \lambda(1+\lambda) \implies 1-\alpha\lambda = \frac{1}{1+\lambda} \tag{92}$$

Отсюда мы находим оптимальный размер шага:

$$\alpha_{opt} = \frac{1}{1+\lambda} \tag{93}$$

Гениальность шага (93) состоит в том, что реальная длина смещения в локальной метрике составляет $\|\alpha_{opt} h_N\|_y = \alpha_{opt}\lambda = \frac{\lambda}{1+\lambda} < 1$. Метод гарантированно не выходит за пределы единичного локального эллипсоида, внутри которого мажоранта абсолютно надежна.

Подставляя $\alpha_{opt}$ в мажоранту, получаем строгую гарантию убывания целевой функции на каждой итерации:

$$\varphi(y_{new}) \leqslant \varphi(y) - (\lambda - \ln(1+\lambda)) \tag{94}$$

Сходимость такого алгоритма строго делится на две фазы:

1. **Демпфированная фаза** (пока $\lambda > 1/4$). Мы находимся далеко от оптимума. Декремент большой, шаг $\alpha_{opt}$ мал. Функция гарантированно убывает минимум на абсолютную константу $\Delta\varphi \geqslant 1/4 - \ln(1.25) > 0$. Количество итераций этой фазы ограничено сверху величиной $\mathcal{O}\left(\frac{\varphi(y_0)-\varphi^*}{\Delta\varphi}\right) = \mathcal{O}\left(\frac{1}{\varepsilon}\right)$.

2. **Квадратичная фаза** (когда $\lambda \leqslant 1/4$). Мы вошли в локальную окрестность оптимума. Декремент мал, шаг $\alpha_{opt} \approx 1$. Метод переходит в режим классического Ньютона. Можно показать, что декремент начинает убывать квадратично: $\lambda_{k+1} \leqslant 2\lambda_k^2$. Достижение любой машинной точности требует около 5-6 итераций, что можно сказать равно $\mathcal{O}(1)$.

**Итоговая вычислительная сложность:**
Количество внешних итераций метода составляет $\mathcal{O}(1/\varepsilon)$. На каждой такой итерации мы ищем направление $h_N$ за $\mathcal{O}(n^2)$. Таким образом, общая сложность алгоритма составляет:

$$\mathcal{O}\left(\frac{n^2}{\varepsilon}\right) \tag{95}$$

В совокупности это позволяет методам второго порядка достигать теоретической сложности лучших ускоренных методов первого порядка, а на практике даже переигрывать их за счет за счет наличия фазы локальной квадратичной сходимости.