Энтропийный оптимальный транспорт: анализ двойственности и методы оптимизации

Выполнил: студент гр. Б05-406 Подсветов И.Р.

Научные руководители: Агафонов А.Д., Гасников А.В.

Московский физико-технический институт
Физтех-школа прикладной математики и информатики

2026

План доклада

1. Постановка задачи и регуляризация
2. Двойственность и методы первого порядка
3. Базовые методы второго порядка и Эксперименты
4. Современные методы второго порядка
5. Заключение

Классическая транспортная задача

Постановка: Минимизация расходов на перемещение груза от n источников к m потребителям.

$$\min_d \sum_{i,j} T_{ij} d_{ij}$$

Ограничения (законы сохранения):

- $\sum_{j=1}^m d_{ij} = O_i$ (весь груз из источника i должен быть вывезен)
- $\sum_{i=1}^n d_{ij} = D_j$ (потребности узла j должны быть удовлетворены)
- $d_{ij} \geqslant 0$ (условие неотрицательности потока)

Проблемы линейного программирования в ОТ

Использование классического ЛП имеет ряд критических недостатков:

1. **Нестабильность решения:** Область допустимых значений — многогранник. Оптимум достигается в вершинах. Малейшее изменение вектора стоимостей T заставляет решение «перепрыгивать» в другую вершину, полностью меняя структуру транспортных потоков.
2. **Разреженность:** Решение представляет собой нули везде, кроме нескольких выгодных маршрутов. При моделировании реальных процессов (например, перемещения людей) потоки распределяются более равномерно.

Энтропийная регуляризация

Для устранения этих проблем вводится **энтропийный регуляризатор**:

$$\min_d \left[\sum_{i,j} T_{ij} d_{ij} + \gamma \sum_{i,j} d_{ij} \ln d_{ij} \right]$$

Свойства и интерпретация

- **Строгая выпуклость:** Функция $x \ln x$ строго выпукла. Добавляя её, мы создаем плавный минимум внутри допустимой области, что обеспечивает гладкую зависимость решения от входных данных.
- **Термодинамика:** Минимизируется свободная энергия Гельмгольца $F = E - TS$.
- **Роль γ:** Действует как температура.
  - $\gamma \to 0$: система стремится к минимуму энергии (исходная задача).
  - $\gamma \to \infty$: максимизируется хаос, потоки распределяются равномерно.

Векторизация задачи

Для удобства математического анализа перейдём от матриц к векторам. Вытянем матрицу потоков $d \in \mathbb{R}_+^{n \times m}$ и матрицу стоимостей T в векторы:

$$x \in \mathbb{R}^N, \quad c \in \mathbb{R}^N, \quad \text{где } N = n \cdot m$$

Ограничения-равенства (баланс масс) объединим в единую систему $Ax = b$:

- Вектор $b = \begin{pmatrix} O \\ D \end{pmatrix} \in \mathbb{R}^{n+m}$
- Матрица $A \in \mathbb{R}^{(n+m) \times N}$ — матрица ограничений (состоит из нулей и единиц).

Модифицированная целевая функция:

$$\min_{x>0} \left[\langle c, x \rangle + \gamma \sum_{i=1}^{N} x_i (\ln x_i - 1) \right] \quad \text{при условии } Ax = b$$

Функция Лагранжа и вывод двойственной задачи

Введём вектор двойственных переменных $y \in \mathbb{R}^{n+m}$ для ограничений $Ax = b$ и выпишем функцию Лагранжа:

$$\mathcal{L}(x, y) = \langle c, x \rangle + \gamma \sum_{i=1}^{N} x_i(\ln x_i - 1) + \langle y, Ax - b \rangle$$

Минимизируем $\mathcal{L}$ по прямым переменным x:

$$\nabla_x \mathcal{L} = 0 \implies c_i + \gamma \ln x_i + (A^T y)_i = 0$$

Отсюда получаем аналитический вид транспортного плана:

$$x_i(y) = \exp\left(-\frac{c_i + (A^T y)_i}{\gamma}\right)$$

Подставляя $x(y)$ обратно в Лагранжиан и переходя к эквивалентной задаче минимизации, получаем безусловную **двойственную задачу**:

$$\varphi(y) = \langle y, b \rangle + \gamma \sum_{i=1}^{N} \exp\left(-\frac{c_i + (A^T y)_i}{\gamma}\right) \to \min_{y \in \mathbb{R}^{n+m}}$$

Ключевые свойства двойственной функции

Переход к двойственной задаче $\varphi(y)$ дает нам удобную безусловную оптимизацию.

1. **Связь прямой и двойственной задачи:** Градиент двойственной функции в точности равен невязке ограничений прямой задачи:

$$\nabla\varphi(y) = b - Ax(y)$$

2. **Выпуклость:** Матрица Гессе $\nabla^2\varphi(y)$ неотрицательно определена - выпуклость есть. Однако сильной выпуклости нет.
3. **Гладкость (Липшицев градиент):** Функция имеет Липшицев градиент, но константа Липшица обратно пропорциональна регуляризации:

$$L \sim \frac{1}{\gamma}$$

Классический градиентный спуск

Шаг алгоритма: $y_{k+1} = y_k - \frac{1}{L}\nabla\varphi(y_k)$

Используя свойство Липшицевости градиента, выводим лемму о достаточном убывании:

$$\varphi(y_{k+1}) \leqslant \varphi(y_k) - \frac{1}{2L}\|\nabla\varphi(y_k)\|^2$$

Просуммировав по итерациям (телескопическая сумма) и выразив норму градиента, получаем ограничение на невязку:

$$\min_{0\leqslant i\leqslant k}\|\nabla\varphi(y_i)\| \leqslant \mathcal{O}\left(\frac{L}{\sqrt{k}}\right)$$

Следовательно, для достижения требуемой точности по невязке $\|\nabla\varphi(y)\| \leqslant \varepsilon$, потребуется $k = \mathcal{O}\left(\frac{L}{\varepsilon^2}\right)$ итераций.

Классический метод Нестерова

Для ускорения применяют методы с использованием инерции.
Классический метод Нестерова использует две последовательности точек:

$$v_k = y_k + \frac{k-1}{k+2}(y_k - y_{k-1})$$

$$y_{k+1} = v_k - \frac{1}{L}\nabla\varphi(v_k)$$

Критическая проблема

Теорема Нестерова гарантирует ускоренное убывание значения самой функции: $\varphi(y_k) - \varphi^* \leqslant \frac{CL}{k^2}$. Однако норма градиента (которая в нашей задаче является **невязкой ограничений**) убывает **немонотонно** и сильно осциллирует.

Ускоренный градиентный спуск (Primal-Dual подход)

Решение (П. Двуреченский, А. Гасников, А. Крошнин): Не использовать транспортный план из последней точки. Вместо этого строится *усредненный план* из всех предыдущих итераций алгоритма:

$$\hat{x}_k = \frac{1}{A_k} \sum_{i=0}^{k} \alpha_i x(w_i), \quad A_k = \sum_{i=0}^{k} \alpha_i = \mathcal{O}\left(\frac{k^2}{L}\right)$$

Благодаря усреднению (и базовому энергетическому неравенству метода), невязка монотонно убывает:

$$\|b - A\hat{x}_k\| \leqslant \frac{2D}{A_k} = \mathcal{O}\left(\frac{L}{k^2}\right)$$

Сходимость по невязке ускорилась с $\mathcal{O}(1/\sqrt{k})$ до $\mathcal{O}(1/k^2)$!

Вычислительная сложность методов первого порядка

Ключевой теоретический факт: Наша глобальная цель — найти ε-приближенное решение **исходной** (нерегуляризованной) задачи. Для этого необходимо выбирать параметр:

$$\gamma = \mathcal{O}(\varepsilon)$$

Это вызывает неизбежный «взрыв» константы Липшица: $L \sim 1/\varepsilon$.

Итоговые оценки алгоритмов (с учетом шага $\mathcal{O}(n^2)$)

- **Обычный градиентный спуск:** $k = \mathcal{O}\left(\frac{L}{\varepsilon^2}\right) \implies \mathcal{O}\left(\frac{1}{\varepsilon^3}\right)$.
  Итоговая сложность: $\mathcal{O}\left(\frac{\mathbf{n^2}}{\varepsilon^3}\right)$.
- **Primal-Dual метод:** $k = \mathcal{O}\left(\sqrt{\frac{LD}{\varepsilon}}\right) \implies \mathcal{O}\left(\frac{n^{1/4}}{\varepsilon}\right)$.
  Итоговая сложность: $\mathcal{O}\left(\frac{\mathbf{n^{9/4}}}{\varepsilon}\right)$.

Проблема классического метода Ньютона

Естественным развитием является переход к методам второго порядка. Шаг ищется из минимизации квадратичного приближения:

$$\nabla^2\varphi(y_k)h = -\nabla\varphi(y_k)$$

Проблема: Для нахождения шага h необходимо обратить Гессиан. Но в задаче оптимального транспорта Гессиан $\nabla^2\varphi(y)$ лишь неотрицательно определен ($\succeq 0$) и имеет нулевые собственные значения (из-за баланса масс $\sum O_i = \sum D_j$).
Матрица вырождена, прямое обращение невозможно. Классический Ньютон не работает.

Метод Кубического Ньютона

Гессиан Липшицев с константой M. Тогда строится глобальная кубическая мажоранта. Модифицированная система для шага h_k:

$$\left(\nabla^2\varphi(y_k) + \frac{M}{2}\|h_k\|I\right) h_k = -\nabla\varphi(y_k)$$

Матрица становится строго положительно определенной и обратимой.

Вычислительные недостатки:

1. На каждой итерации решается плотная СЛАУ размера $(n+m)\times(n+m)$, что требует $\mathcal{O}(n^3)$ операций.
2. Третья производная вносит зависимость от $1/\gamma$, следовательно константа M растет как $M \sim \frac{1}{\gamma^2} \sim \frac{1}{\varepsilon^2}$.

Итоговая сложность кубического Ньютона: $\mathcal{O}\left(\frac{\mathbf{n}^3}{\varepsilon^{2.5}}\right)$.

Переход к демонстрации экспериментов

На примере одномерной задачи оптимального транспорта проведено эмпирическое сравнение алгоритмов первого и второго порядка:

- Классический градиентный спуск
- Классический метод Нестерова (осцилляции)
- Primal-Dual подход (усредненный план)
- Метод Кубического Ньютона

Современный Ньютон: Структура Гессиана

Как преодолеть кубическую сложность $\mathcal{O}(n^3)$ одной итерации?
Вектор двойственных переменных разбивается на блоки источников u и потребителей v.
Вычислим строгий вид матрицы Гессе. Она распадается на 4 блока:

$$\nabla^2\varphi(u,v) = \frac{1}{\gamma}\begin{pmatrix} D_1 & X \\ X^T & D_2 \end{pmatrix}$$

где D_1 и D_2 — **диагональные** матрицы, а X — матрица почти совпадающая с матрицей транспортного плана.
Система $\nabla^2\varphi\Delta y = -\nabla\varphi$ распадается на два уравнения:

$$D_1\Delta u + X\Delta v = g_u$$
$$X^T\Delta u + D_2\Delta v = g_v$$

Современный Ньютон: Дополнение Шура

Матрица D_2 диагональна, ее обращение тривиально $\mathcal{O}(m)$. Аналитически исключим переменные Δv:

$$\Delta v = D_2^{-1}(g_v - X^T \Delta u)$$

Подставляя это в первое уравнение, получаем СЛАУ уменьшенной размерности (только $n \times n$ вместо $(n+m)$):

$$(D_1 - XD_2^{-1}X^T)\Delta u = g_u - XD_2^{-1}g_v$$

Матрица $S = (D_1 - XD_2^{-1}X^T)$ называется **Дополнением Шура**. СЛАУ стала меньше, но прямое обращение S все еще стоит $\mathcal{O}(n^3)$.

Современный Ньютон: Сопряженные градиенты (CG)

Прорыв: Используем итерационный **метод Сопряженных Градиентов (CG)**. Ему не нужна матрица S в явном виде, требуется лишь вычислять ее произведение на вектор w:

$$p = Sw = D_1 w - X\left(D_2^{-1}(X^T w)\right)$$

Покомпонентный анализ сложности:

1. $q_1 = X^T w$ — умножение матрицы $(m \times n)$ на вектор $\implies \mathcal{O}(mn)$.
2. $q_2 = D_2^{-1} q_1$ — поэлементное умножение вектора $\implies \mathcal{O}(m)$.
3. $q_3 = X q_2$ — умножение матрицы $(n \times m)$ на вектор $\implies \mathcal{O}(mn)$.

Итого, шаг CG стоит всего $\mathcal{O}(n^2)$ операций. Доказывается, что для S алгоритм CG сходится за $\mathcal{O}(1)$ шагов. Вычислительная сложность итерации Ньютона **решена**!

Современный Ньютон: Локальная метрика

Осталась вторая проблема — огромная константа Липшица $L \sim 1/\varepsilon$ ($M \sim 1/\varepsilon^2$), из-за которой длина шага стремится к нулю.
Чтобы избавиться от глобальных констант, откажемся от Евклидовой метрики. Введем **локальную полунорму**, порожденную самим Гессианом в текущей точке:

$$\|h\|_y = \sqrt{\langle \nabla^2 \varphi(y) h, h \rangle}$$

Декремент Ньютона и Самосогласованность

Введем меру близости к оптимуму — **Декремент Ньютона**:

$$\lambda(y) = \|h_N\|_y = \sqrt{\langle -\nabla\varphi(y), h_N\rangle}$$

При смещении из точки y Гессиан искажается. Для контроля этого искажения Ю. Нестеровым была введена концепция **самосогласованности** (Self-Concordance). Для двойственной функции доказано неравенство:

Фундаментальное неравенство

$$|\nabla^3\varphi(y)[h,h,h]| \leqslant 2\|h\|_y^3$$

Главная особенность: В этом дифференциальном неравенстве **нет внешних констант**. Ни L, ни M, зависящих от параметра $\gamma \to 0$. Геометрия функции ограничивает сама себя.

Аналитическая мажоранта

Вывод оценки опирается на рассмотрение одномерного сечения $\varphi(t) = \varphi(y + th_N)$. Интегрируя дифференциальное неравенство трижды, мы получаем точную аналитическую мажоранту Нестерова:

$$\varphi(y + \alpha h_N) \leqslant \varphi(y) - \alpha\lambda^2 - \alpha\lambda - \ln(1 - \alpha\lambda)$$

- Данная оценка полностью заменяет кубическую аппроксимацию.
- Она не зависит от глобальных констант Липшица.

Демпфированный шаг и итоговая сходимость

Минимизируя мажоранту по α, находим **оптимальный скалярный шаг**:

$$\alpha_{opt} = \frac{1}{1+\lambda}$$

Сходимость алгоритма строго делится на две фазы:

1. **Демпфированная фаза** ($\lambda > 1/4$): Находимся далеко от оптимума. Шаг мал ($\alpha < 1$). Функция убывает минимум на абсолютную константу $\Delta\varphi \geqslant 0.02 > 0$. Количество итераций этой фазы ограничено величиной $\mathcal{O}(1/\varepsilon)$.
2. **Квадратичная фаза** ($\lambda \leqslant 1/4$): Вошли в локальную окрестность оптимума. Шаг $\alpha \approx 1$. Декремент убывает квадратично: $\lambda_{k+1} \leqslant 2\lambda_k^2$. Машинная точность достигается за ~ 5 итераций ($\mathcal{O}(1)$).

Итоговая вычислительная сложность

Соберем все элементы воедино:

- Благодаря **Самосогласованности** и локальной норме, метод избавился от зависимости $1/\varepsilon^2$ и требует лишь $\mathcal{O}(1/\varepsilon)$ внешних итераций.
- Благодаря **Дополнению Шура** и методу **CG**, поиск направления шага Ньютона на каждой итерации занимает всего $\mathcal{O}(n^2)$ операций.

Общая вычислительная сложность современного метода Ньютона для энтропийного оптимального транспорта составляет:

$$\mathcal{O}\left(\frac{\mathbf{n^2}}{\varepsilon}\right)$$

Заключение и Итоги

Алгоритм оптимизации	**Теоретическая сложность**
Классический градиентный спуск	$\mathcal{O}\left(n^2/\varepsilon^3\right)$
Ускоренный метод 1-го порядка (Primal-Dual)	$\mathcal{O}\left(n^{2.25}/\varepsilon\right)$
Классический метод Кубического Ньютона	$\mathcal{O}\left(n^3/\varepsilon^{2.5}\right)$
Ньютон (Шуровское дополнение + Самосогласованность)	$\mathcal{O}\left(\mathbf{n^2}/\varepsilon\right)$

Доклад окончен

Полный текст отчета и программная реализация методов (Jupyter Notebook) доступны в репозитории:

`github.com/ilapodsvetov/optimal-transport-optimization`